Estruturação da Memória Agêntica

Intro ao serviço de memória e principais premissas:

O serviço de memória tem como objetivo gerar “inteligência” individual e coletiva sobre os nossos principais stakeholders no iFood, sejam eles Consumers(CX), Parceiros(PX) ou Drivers(DX). Dado as possibilidades de formato e consumo, desenhamos um modelo inicial para simplificar-abstrair complexidade para os times (builders) que poderão utilizar desse serviço.

A solução é composta de três camadas: a primeira chamada de INTEL é a que fica disponível para consumo dos builders, Tools e Capabilities e Infra são direcionadas para compor a inteligência e são transparentes para os usuários. A camada de **INTEL**, composta por duas estruturas macro e agnósticas aos *stakeholders(CX, PX, DX), são elas*: **Relacionamento** e **Personalização**. Elas contêm categorias de informações essenciais (o "80-20") para o Agente que consome o serviço entender o cenário de cada *stakeholder*, como: pendências, sugestões não acatadas, fricções e alertas.

O que forma a camada de INTEL (para consumo de informações), é camada de **tools e capabilities que é transparente para os builders**, responsável por construir essas informações. Nessa camada, ferramentas como LCMs, RAGs e Resumos estão disponíveis para buscar, resumir e conectar pontos relevantes que compõem a memória-informação necessária para o Agente atuar.

Por fim, a camada de **abastecimento** é onde os dados são configurados. Ela define fontes, ingestão, formato e sazonalidade dos dados para que sejam utilizados pela camada de Tools e Capabilities, alimentando toda a inteligência.

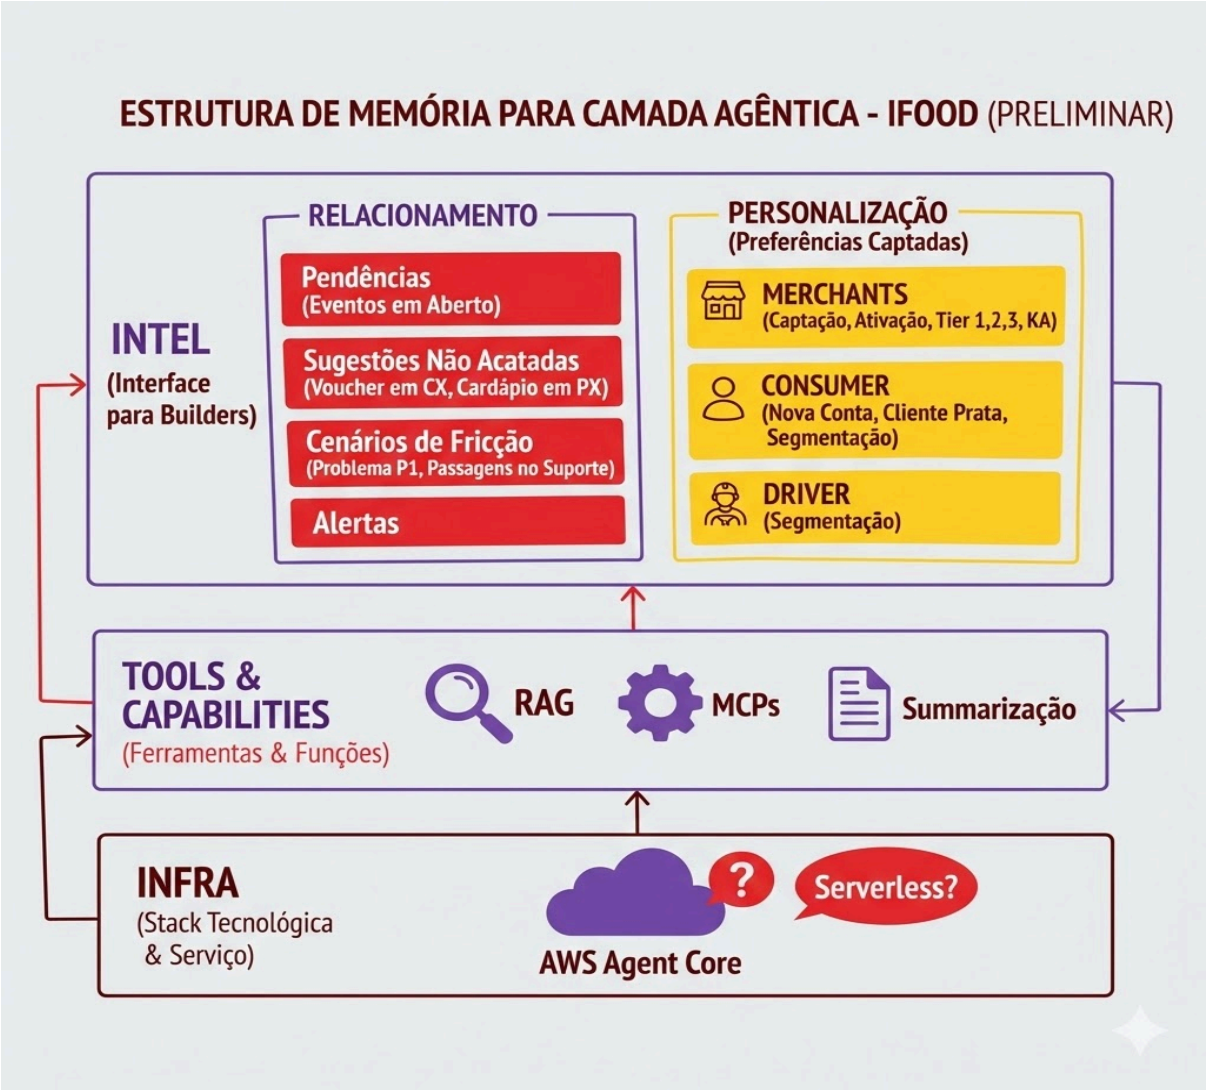

Exemplos de Uso:

Consumer: Temos hoje contato com o consumidor via Ailo e Anota AI no pré pedido e no pós pedido a Rosie.

INTEL: Temos o entendimento do Relacionamento e Personalização de cada cliente, seja no pré e pós pedido:

Relacionamento:

- Pendências: Temos vouchers pendentes, pedidos pendentes, algum item de segurança no cadastro.
- Sugestões não acatadas: Recomendações, vouchers não utilizados, promo e outros gatilhos.
- Fricção: Tivemos problemas em pedidos com restaurantes ABC, O atendimento foi conturbado.

Personalização:

- Hábitos de consumo
- Preferência de tom de voz de comunicação

-

Caso haja necessidade do agente em aprofundar em algum tema seja de relacionamento ou de personalização cabe a ele fazer a requisição que a camada de Tools e Capabilties irá trazer a informação com mais detalhes. Caso a informação requisitada esteja indisponível iremos ter o log para entender como incorporar no caso de uso para o consumidor.

Na prática, definida a governança, todos os agentes envolvidos com o consumidor que utilizam o serviço de memória fornecem informações para refinar a estrutura e usam essas informações - inteligência individual e coletiva

Merchant: O merchant tem contato com a Diana Captação e Ativação, Cris e Karen (preciso captar as infos dentro de Pago)

INTEL: Temos o entendimento do Relacionamento e Personalização de cada merchant e sua fase no iFood

Relacionamento:

- Pendências: de contrato, setup, handshake e etc
- Sugestões não acatadas: Recomendações de setup gerais e produtos Ecossistema iFood.
- Fricção: Tivemos e-ou temos qualquer ponto de fricção com esse restaurante.

Personalização:

- Horário de contato
- tom de voz
- Estágio de maturidade dado seu segmento

O mesmo segue para o agente que queira se aprofundar em algum ponto mais específico da memória e do entendimento episódico e semântico com o parceiro.

Atendimento: Esse é um caso de uso diferente e cross, pois envolve o ticket com merchant, driver e consumer. É uma visão 360 sobre o ocorrido em qualquer problema com o pedido. Esse é um caso que podemos considerar mais avançado, pois o problema pode ocorrer simultâneamente para todos os stakeholders envolvidos, de modo que, precisamos utilizar de estratégias tipo “blackboard” atualizadas de forma NRT para tomarmos melhores decisões.

A premissa de inteligência coletiva, mesmo que em domínios diferentes, ainda vale, assim como o Relacionamento e Personalização com cada stakeholder envolvido (CX, PX, e DX).

Plano Implementação Até 29-01

O plano de implementação tem o objetivo de entregar memória sobre o Merchant, o primeiro caso direto para Diana (domínio Merchant). A proposta é entregar duas linhas dentro da INTEL-Relacionamento, que são capacidade de entendimento das Pendências e

das Fricções. Esse será o nosso teste inicial no início de fevereiro. Depois disso seguimos nossos próximos passos, expandindo outras atividades da INTEL de relacionamento e para os demais agentes dentro do domínio de Parceiros.

Atividades e Pontos Macro	**14-01**	**16-01**	**21-01**	**23-01**	**27-01**	**29-01**
Comparativos Serviços	Jeferson …					
Desenho Estrutura Solução		Todo o Grupo - Finalizar a resposta				
Desenho Adapter			Lucas de… Karlla De…			
Desenho Eng - Ingestão e Infra			Vinicius …			
Definição Caso de Uso		Grupo todo				
Definição 1º Teste		Grupo todo				
Implementação 1º Teste					Karlla … Lucas … Vinicius…	
Testes Diana						Time Diana + Karlla De… Vinicius … Lucas de…

Plano de Implementação
Até 29-01

Data	Atividade	Responsável(eis)
14-01	Comparativos de Serviços (Análise Inicial)	Jeferson "Jef" Santos
16-01	Desenho da Estrutura da Solução (Resposta Final)	Todo o Grupo
16-01	Definição do Caso de Uso	Todo o Grupo
16-01	Definição do 1º Teste	Todo o Grupo
21-01	Desenho do Adapter	Lucas de Miranda (Miranda), Karlla Delalibera
21-01	Desenho de Engenharia (Ingestão e Infraestrutura)	Vinicius Bandeira
27-01	Implementação do 1º Teste	Karlla Delalibera, Lucas de Miranda (Miranda), Vinicius Bandeira
29-01	Testes com Diana	Time Diana, Karlla Delalibera, Vinicius Bandeira, Lucas de Miranda (Miranda)

Formato inicial da construção:

- Baseado em três camadas de construção
    - **Infra**, que é stack tecnológica que iremos utilizar, formato do serviço (serveless ou não)
        - AWS Agent Core -
    - **Tools e capabilities**
        - Ferramentas que podemos utilizar, ex: RAG, MCPs
        - Capabilities como sumarização
    - **INTEL** - Camada de Interface para os Builders
        - **Relacionamento**:
            - Pendências - eventos em aberto
            - Sugestões não acatadas (voucher em CX, Cardápio em PX)
            - Cenários de Fricção (Problema P1, Passagens no suporte sobre pedidos)
            - Alertas
        - **Personalização**:
            - Preferências captadas - Cenário Atual no Ifood
                - **Merchants**

        - Captação
        - Ativação
        - Tier 1,2,3, KA
    - **Consumer** - LCM, Profile
        - Nova Conta
        - Cliente Prata (+ ou -), segmentação
        -
    - **Driver**
        - Segmentação
    - **Order -** entidade que pode ser bem importante pra nós, pois é o agrupamento

Dores: DIANA

Papo com Aldo Fernandes

As principais dores mencionadas por Aldo Fernandes e como o uso da estrutura de memória no agente Diana pode ajudar a resolvê-las, conforme as anotações e a transcrição da reunião, são:

Dor Principal	Como a Estrutura de Memória Ajuda a Resolver
Limitação da Memória de Curto Prazo (24 horas)	A memória de curto prazo atual (24 horas, limite da sessão Meta) leva à perda de informações cruciais para usuários que demoram mais para concluir a ativação. O plano é que a própria Diana comece a guardar informações, alterando esse cenário.
Falta de Personalização e Contexto para *Growth*	A personalização é vista como uma estratégia-chave para aumentar o engajamento e a conversão (*growth*) no início da jornada. A memória permite que a Diana utilize informações prévias (CPF/CNPJ, histórico como consumidor/entregador, interações passadas) para:<ul><li>Adequar o tom de voz do atendimento (por exemplo, ser mais direta se a experiência anterior com a Rose indicou essa preferência).</li><li>Enriquecer modelos de recomendação (catálogo, horário de funcionamento, etc.).</li></ul>
Falta de Histórico de Conversas e Recomeço do Zero	A perda do histórico de mensagens trocadas impede o avanço do processo. Se um erro ocorre em uma conversa inicial, a interação é reiniciada do zero dias depois, perdendo o contexto e a oportunidade de adiantar o fluxo. A memória de longo prazo agilizaria a retomada de conversas, permitindo que a Diana soubesse o que o usuário já fez e adiantasse etapas.

Fricção na Jornada de Ativação (Captação e Ativação)	Entender o que aconteceu na fase de Captação (externa, feita pelo SalesForce) é fundamental para otimizar a Ativação (agente interno). Se o registro da conversa de Captação for acessível, a Diana (Ativação) pode:<ul><li>Abordar proativamente preocupações levantadas (ex: modelo de repasse) durante a fase de dados bancários, reduzindo a fricção e as barreiras que levam a desistências.</li></ul>

Para resolver essas questões de dados e memória, Aldo mencionou a implementação futura de uma coluna de ***session variables*** no *data product* da Diana de ativação, seguindo o padrão da Rose, para capturar um *snapshot* das informações da sessão de curto prazo no momento do evento e enriquecer os dados.

Papo Bruno Maia :

Segue o resumo tabular das dores sobre memória que Bruno Maia trouxe durante a reunião:

Problema de Memória	Descrição Detalhada	Solução Sugerida/Contexto
Agente Diana Duplicado e Sem Memória Compartilhada	Existem duas versões do agente Diana (uma da Sales Force e uma proprietária com stack própria), e não há memória integrada ou compartilhada entre elas, impedindo que uma trabalhe com o histórico da outra.	Ele defende que o ideal é passar o *summary* (resumo) do acontecimento de um agente para o outro para que o histórico seja mantido e não se comece do zero.
Perda da Memória de Curto Prazo (Dor Principal)	A Diana proprietária perde a memória de curto prazo (curta duração) quando o usuário encerra a sessão do WhatsApp por mais de 24 horas e retorna depois desse período. Ele classificou isso como sua "dor principal" (80/20).	É vista como uma solução interna (dentro da própria Diana) a ser resolvida antes de alimentar a memória universal. A meta é ter a memória interna da Diana funcionando até o final de fevereiro.
Risco com Múltiplos Agentes Sem Memória Integrada	O time comercial está utilizando muitos agentes sem memória integrada, o que representa um "grande risco de quebra de informação, de informação errada".	Bruno defende estrear a Diana na solução de **memória universal** que o time de Jeferson está construindo para economizar energia e evitar esforços locais.

Complexidade da Comunicação Multimodal	O armazenamento de multimídia (imagem ou vídeo) no histórico é complexo, pois gera base64 e o LLM o interpreta, além do desafio de representar a riqueza da imagem versus apenas sua transcrição em texto.	A solução temporária sugerida é guardar o arquivo no S3 e o URL na Diana.
Armazenamento de Embeddings Trava o Modelo	Descartaram armazenar a memória diretamente como *embeddings* (vetores) porque isso "travaria a memória" em um modelo específico, o que é problemático devido à rápida evolução dos modelos de linguagem.	Estão armazenando a memória como um documento JSON (usando Redis) e planejam processá-lo com um LLM/SLM para subir o resumo para a memória universal.

Dores AILO:

(papo com Renan de Padua)

Dor Identificada (Cenário Atual)	Solução Proposta (Nova Estrutura)	Detalhe da Implementação na Ailo
1. Limitação à Janela de Sessão O agente perde o contexto assim que a conversa termina. Não sabe o que ficou "em aberto".	**Camada INTEL - Relacionamento (Pendências)** A nova estrutura cria uma categoria fixa de "Relacionamento" que persiste estados que transcendem a sessão atual[1111].	A Ailo passará a consultar o bloco de **"Pendências"**, identificando vouchers não utilizados ou pedidos que ficaram pendentes em interações anteriores, mantendo o contexto vivo entre sessões distintas 2.

2. Falta de Persistência de Preferências O agente esquece gostos (ex: comida favorita) e comportamentos do usuário (ex: tom de voz) a cada nova interação.	**Camada INTEL - Personalização** Criação de uma estrutura dedicada a armazenar preferências captadas e segmentação do cliente, acessível a qualquer momento[3333].	A solução armazena explicitamente **"Hábitos de consumo"** e **"Preferência de tom de voz"**[4]. Isso permite que a Ailo inicie a conversa já sabendo como falar e o que oferecer, sem "reaprender" o usuário.
3. Perda de Contexto de Fricção O agente não lembra de experiências negativas passadas, podendo sugerir um restaurante que já deu problema.	**Camada INTEL - Relacionamento (Fricção)** A memória passa a registrar cenários de alerta e problemas anteriores para evitar repetição de erros[555].	A Ailo terá acesso ao histórico de **"Fricção"**, identificando se o cliente teve problemas com o "restaurante ABC" ou se o atendimento anterior foi conturbado, ajustando a sugestão ou a abordagem[6].
4. Dificuldade em Consolidar/Resumir Dados Necessidade de processar logs brutos para extrair inteligência útil.	**Camada Tools & Capabilities (Sumarização e RAG)** Implementação de uma camada funcional transparente para os *builders* que processa e	Se a Ailo precisar de detalhes sobre uma "Sugestão não acatada" (ex: por que o cliente rejeitou uma promo anterior), ela aciona a camada de **Tools** que usa sumarização para trazer o contexto detalhado, transformando logs em inteligência acionável[8888].

	resume a informação bruta[7].	

Exemplos de Uso: